

Utilisation du Machine Learning avec Python pour la Prédiction des Zones à Risque

Approche KDD · One Health · Épidémiologie Environnementale

10 Mai 2026 · 08h30–10h00 GMT+2 · Google Meet

Jean-Lumière KAMOLE | Modérateur : Steven KUSINZA

Plan de la Présentation

01

Pipeline KDD

Knowledge Discovery in Databases

02

Pré-traitement & Variables

Nettoyage, sélection, transformation

03

Machine Learning

Supervisé vs Non-supervisé

04

Régression → Classification

Approche Two-Step & Métriques

05

Interprétation du modèle

SHAP & Feature Importance

06

Cartographie avec Python

GeoPandas & Folium

01 · Pipeline KDD

Knowledge Discovery in Databases

Pipeline KDD – Vue d'ensemble

Compréhension
du Problème

Collecte &
Pré-traitement

Sélection &
Transformation

Machine
Learning

Interprétation
& Cartographie

Notre jeu de données : 400 observations · 20 variables · Sites d'infestation aquatique

Pourquoi le KDD ?

Le KDD structure la démarche scientifique : du problème terrain à la carte de risque exploitable par les décideurs de santé publique.

Notre question centrale

Quels facteurs environnementaux (pH, TDS, végétation...) prédisent le taux d'infestation des sites aquatiques ?

Résultat attendu

Un modèle ML capable de classer et cartographier les zones à risque élevé pour orienter les interventions One Health.

Étape 1 · Compréhension du Problème

Pourquoi bien comprendre le problème ?

- Définir les deux variables cibles : total (nb mollusques) et Taux_infestation (vecteur)
- Identifier le type de tâche ML : classification ou régression ?
- Choisir les métriques d'évaluation adaptées dès le départ
- Éviter de collecter des données inutiles (coûts, biais)
- Impliquer les experts terrain (biologistes, épidémiologistes)
- Orienter l'interprétation des résultats vers l'action

Notre Dataset · 400 obs. · 20 variables

Identifiant

Site, Latitude, Longitude, Altitude

Temporel

Month, Season

Biologique

Species, Algues, Végétation

Physico-chim.

pH, TDS, EC, Alcalinité, PO4, NO3

Géo-morpho.

Profondeur, Nature_fond

Cibles (Y)

total → Régression | Taux_infestation → Classification

02 · Pré-traitement des Données

Nettoyage · Sélection · Transformation

Pré-traitement · Sélection · Transformation des Variables

Pré-traitement

- Valeurs manquantes : imputation (médiane, mode)
- Valeurs aberrantes : IQR, Z-score
- Encodage variables catégorielles (Season, Espèces, Végétation...)
- Normalisation / standardisation (MinMax, StandardScaler)
- Données géospatiales : projection CRS cohérente

Sélection de Variables

- Corrélation de Pearson / Spearman
- Test Chi-2 pour variables catégorielles
- Importance RF / Gradient Boosting
- Élimination récursive (RFE)
- Ex. : pH, TDS, Végétation → corrélés avec total (nb mollusques) et Taux_infestation

Transformation

- Log-transformation (total, TDS) pour réduire l'asymétrie de distribution
- Création de nouvelles features (ratio, interaction)
- Discrétisation : Taux_infestation → Bas / Moyen / Élevé (pour étape 2)
- Analyse en Composantes Principales (ACP)
- Train / Validation / Test split (70-15-15)

03 · Machine Learning

Apprentissage Supervisé & Non-Supervisé

Apprentissage Supervisé vs Non-Supervisé

SUPERVISÉ

La variable cible (Y) est connue — approche Two-Step

- ÉTAPE 1 – Y = total (nb mollusques, continu) → Régression
- ÉTAPE 2 – Y = Taux_infestation (vecteur, catégorie) → Classification
- Algorithmes : Random Forest, XGBoost, Régression Linéaire/Logistique
- Métriques étape 1 : RMSE, R^2 | Étape 2 : ROC-AUC, Précision, Rappel
- → Approche Two-Step retenue pour notre étude

vs

NON-SUPERVISÉ

Pas de variable cible (Y) définie

- Découverte de structures cachées dans les données
- Algorithmes : K-Means, DBSCAN, Clustering Hiérarchique, ACP
- Application : regrouper des sites similaires sans étiquette
- Utile en phase exploratoire avant la modélisation
- → Complément possible pour la segmentation des sites

04 · Approche Two-Step

Régression → Environnement Favorable | Classification → Vecteur de Maladie

Approche Two-Step – Deux Questions, Deux Modèles

ÉTAPE 1 · RÉGRESSION

? Question posée

Quel est l'environnement favorable aux mollusques ?

🎯 Variable cible Y

total → Nombre de mollusques collectés (valeur continue)

🔧 Algorithmes

Random Forest Regressor, XGBoost Regressor, Ridge Regression

📊 Métriques

RMSE · MAE · R^2 (coefficient de détermination)

ÉTAPE 2 · CLASSIFICATION

? Question posée

Dans quel environnement les mollusques deviennent-ils vecteurs de maladies ?

🎯 Variable cible Y

Taux_infestation → Bas / Moyen / Élevé (catégorie ordonnée)

🔧 Algorithmes

Random Forest Classifier, XGBoost, SVM, Régression Logistique

📊 Métriques

Précision · Rappel · F1-Score · AUC-ROC · Matrice de confusion

nourrit

💡 Les prédictions de total (étape 1) peuvent enrichir les features de l'étape 2 — logique écologique respectée

Étape 2 · Métriques de Classification – Taux_infestation Vecteur

Matrice de Confusion

	Prédit Positif	Prédit Négatif
Réel Positif	VP (Vrai Positif)	FN (Faux Négatif)
Réel Négatif	FP (Faux Positif)	VN (Vrai Négatif)

VP : correctement classé positif **VN** : correctement classé négatif

FP : fausse alarme (erreur type I) **FN** : positif manqué (erreur type II)

Courbe ROC-AUC : mesure la capacité du modèle à distinguer les sites vecteurs des non-vecteurs.

AUC = 1 → parfait | AUC = 0.5 → aléatoire

Formules & Interprétation

Précision (Precision)

$$VP / (VP + FP)$$

Parmi les sites classés 'vecteurs', combien le sont réellement ? (éviter faux positifs)

Rappel (Recall / Sensibilité)

$$VP / (VP + FN)$$

Parmi tous les vrais sites vecteurs, combien avons-nous détectés ? (ne pas rater un foyer)

F1-Score

$$2 \times (\text{Précision} \times \text{Rappel}) / (P + R)$$

Équilibre P/R. Crucial si les sites vecteurs sont rares (classes déséquilibrées).

AUC-ROC

Aire sous la courbe ROC

Plus proche de 1, mieux le modèle discrimine sites vecteurs vs non-vecteurs.

Étape 1 · Métriques de Régression – Prédire le Nombre de Mollusques (total)

RMSE

Root Mean Squared Error

Formule :

$$\sqrt{\sum (Y_i - \hat{Y}_i)^2 / n}$$

Interprétation :

Erreur moyenne en unité de total (nb mollusques). Pénalise les grands écarts.
Ex. : RMSE = 12 → erreur moy. de 12 mollusques sur la prédiction du site.

MAE

Mean Absolute Error

Formule :

$$\sum |Y_i - \hat{Y}_i| / n$$

Interprétation :

Erreur absolue moyenne. Plus facile à communiquer aux non-statisticiens.
Ex. : MAE = 8 → en moyenne, on se trompe de 8 mollusques par site.

R²

Coefficient de Détermination

Formule :

$$1 - \frac{\sum (Y_i - \hat{Y}_i)^2}{\sum (Y_i - \bar{Y})^2}$$

Interprétation :


Part de la variabilité du nombre de mollusques expliquée par les variables env.
R²=0.85 → le modèle explique 85% des variations de l'abondance des mollusques.

05 · Interprétation du Modèle

SHAP Values & Feature Importance

Feature Importance – Quelles variables comptent le plus ?

La Feature Importance mesure la contribution de chaque variable à la prédiction du modèle.
Plus l'importance est élevée, plus la variable influence la classification/régression.



Comment interpréter ?

- pH et TDS sont les principaux déterminants du taux d'infestation dans notre dataset
- La profondeur influence la présence des espèces aquatiques
- Les nutriments (PO4, NO3) favorisent la prolifération des vecteurs
- Les variables catégorielles (Végétation, Algues) ont moins d'importance individuelle
- → Prioriser la collecte de pH et TDS dans les futures missions terrain

SHAP Values – Interprétation Locale & Globale du Modèle

Qu'est-ce que SHAP ?

SHAP (SHapley Additive exPlanations) décompose la prédiction en contributions individuelles de chaque variable.

Pour l'étape 1 (Régression) : quelles variables environnementales expliquent le nombre de mollusques ?


Pour l'étape 2 (Classification) : pourquoi CE site est-il classé vecteur de maladie ? (note : total figure comme feature)

Valeur SHAP positive → pousse vers vecteur/abondance élevée

Valeur SHAP négative → pousse vers non-vecteur/abondance faible

Exemple : Site Classé 'Vecteur Élevé'

Contributions SHAP – Modèle Classification (étape 2)



→ Prédiction finale : $0.35 + 0.59 = 0.94$ → Site VECTEUR : Taux_infestation ÉLEVÉ

06 · Cartographie avec Python

GeoPandas · Folium · Zones à Risque

Cartographie Python – GeoPandas & Folium


GeoPandas

- Étend Pandas pour les données géospatiales (GeoDataFrame)
- Lecture de fichiers Shapefile, GeoJSON, CSV avec coordonnées
- Fusion des prédictions ML avec les géométries de sites
- Création de cartes statiques (matplotlib) colorées par niveau de risque
- Calcul de buffers, intersections, distances entre sites

Folium


- Cartes interactives Leaflet.js via Python
- Marqueurs colorés selon le niveau de risque (Bas/Moyen/Élevé)
- Popups avec détails du site au clic (pH, TDS, espèces...)
- Couches choroplèthes (heatmap d'infestation)
- Export HTML partageable avec partenaires et décideurs

PIPELINE CARTOGRAPHIQUE



Application Concrète – Carte des Zones à Risque

📄 Aperçu Carte Folium (Illustration schématique)



Ce que produit notre analyse

📄 Carte d'abondance (Étape 1)

Zones à forte densité de mollusques : environnements favorables à surveiller en priorité

● Zones Vecteurs (Étape 2 - Élevé)

Sites où les mollusques deviennent vecteurs : interventions sanitaires urgentes requises

📄 Zones Vecteurs (Étape 2 - Moyen)

Surveillance régulière, campagnes de sensibilisation communautaire One Health

📊 Tableau de bord interactif

Rapport HTML Folium partageable avec autorités sanitaires, ONG et partenaires terrain

Conclusion & Perspectives

✓ Pipeline KDD structuré

Une démarche rigoureuse du problème à la carte : gage de reproductibilité et de crédibilité scientifique.

✓ Interprétabilité avec SHAP

pH, TDS et total (nb mollusques prédit) comme variables clés → compréhension des mécanismes écologiques et sanitaires.

✓ Approche Two-Step cohérente

Étape 1 : Régression sur total → identifier l'environnement favorable aux mollusques. Étape 2 : Classification sur Taux_infestation → détecter les sites vecteurs de maladies.

✓ Cartographie interactive

GeoPandas + Folium produisent des cartes actionnables pour les décideurs de santé publique.

✓ Métriques bien choisies

RMSE & R^2 pour la régression (étape 1) · Précision, Rappel, F1, AUC-ROC pour la classification (étape 2).



Merci pour votre attention · Questions & Discussion